

=====

User prompt 1 of 25 - 9/8/2026, 10:11:25 PM:

ии модели без ограничений (цензуры) мне нужны для разработки игры под слабое железо на слабом железе так что мне нужен программист а не собеседник причем точный с возможностью корректировки

GPT-5.6 Luna:

<!-- -->

Понял: вам нужен не «собеседник», а локальный помощник-программист для разработки игры, который:

- работает на слабом компьютере;
- пишет и исправляет код;
- понимает структуру проекта;
- выполняет точные инструкции;
- позволяет постепенно корректировать результат;
- не ограничивает обычные игровые, технические и экспериментальные запросы.

Для такой задачи я бы выбирал не просто «модель без цензуры», а **небольшую open-weight coding-модель в формате GGUF**. Полное отсутствие ограничений не гарантирует качества: для программирования важнее контекст, следование инструкциям, работа с несколькими файлами и способность исправлять ошибки.

Что выбрать по объёму оперативной памяти

| ОЗУ компьютера | Модель | Для чего подходит |

| ---|---|---|

| 8 ГБ | Qwen3 4B/8B, Qwen2.5-Coder 3B/7B | небольшие скрипты, Lua, Godot, Unity C#, исправления |

| 16 ГБ | Qwen3-Coder 7B/14B, DeepSeek-Coder-V2-Lite | полноценная разработка небольшой игры |

| 24–32 ГБ | Devstral Small 24B Q4 или Qwen3-Coder 30B Q4 | работа с несколькими файлами и сложная отладка |

| 6–8 ГБ видеопамати + ОЗУ | Qwen3-Coder 7B Q4/Q5 | хороший баланс скорости и качества |

| Только слабый CPU | Qwen3-Coder 3B/7B Q4 | медленнее, но работать будет |

Для слабого железа наиболее практичный старт — **Qwen3-Coder 7B в квантизации Q4_K_M**. Если компьютер совсем слабый — **Qwen2.5-Coder 3B** или **Qwen3-Coder 3B**. Если есть 16 ГБ ОЗУ и терпимая скорость — можно пробовать **Qwen3-Coder 14B Q4**. Небольшие Qwen-варианты рекомендуются именно для локального программирования на малом объёме памяти; более крупные модели требуют заметно больше ресурсов. [1,2]

Для запуска используйте:

- **LM Studio** — проще всего, если нужен графический интерфейс;
- **llama.cpp** — лучший вариант для максимальной экономии ресурсов;
- **Ollama** — удобен для подключения модели к редактору и инструментам;
- **Continue** или **Cline/Roo Code** в VS Code — чтобы модель видела файлы проекта и могла предлагать изменения.

Рекомендуемый вариант

Если у вас 8–16 ГБ ОЗУ:

```text

Модель: Qwen3-Coder 7B

Формат: GGUF

Квантизация: Q4\_K\_M

Запуск: llama.cpp или Ollama

Редактор: VS Code + Continue

Контекст: 8K–16K токенов

```

Для Godot можно начать с Qwen3-Coder 7B. Для Unity — тоже, но при больших C#-скриптах понадобится больше контекста. Для GameMaker и Lua подойдёт даже 3B–7B. Для Unreal Engine и C++ слабые локальные модели будут значительно менее удобны: там лучше хотя бы 14B, а для серьёзной работы — 24B и выше.

Как сделать модель точнее

Главное — не просить её сразу «сделать всю игру». Рабочий режим должен быть таким:

```text

Ты — программист игры на Godot 4 и GDScript.

Правила:

1. Не переписывай файлы полностью без необходимости.
2. Сначала объясни причину ошибки.
3. Перед изменением укажи, какие файлы затрагиваются.
4. Выводи полный код только изменённых функций.
5. Не добавляй сторонние библиотеки без моего разрешения.
6. Сохраняй существующие названия узлов, переменных и сигналов.
7. После каждого изменения укажи, как проверить результат.
8. Если данных не хватает — перечисли конкретно, что нужно прислать.
9. Не выдумывай API движка.
10. Если исправление неуверенное, предложи два варианта и объясни различия.

```

Ещё лучше работать через Git и давать модели маленькие задачи:

```text

Исправь только прыжок персонажа.

Файл: player.gd

Проблема: персонаж иногда проваливается через платформу.

Ограничения:

- не менять управление;
  - не менять имена переменных;
  - не добавлять плагины;
  - показать точечный патч;
  - объяснить, почему возникла ошибка.
- ...

Такой формат обычно даёт гораздо более точный результат, чем запрос вроде «сделай мне систему боя».

Если нужен именно **максимально неконтролируемый локальный вариант**, ищите open-weight/GGUF-модели и запускайте их локально через llama.cpp или LM Studio. Однако для разработки игры я бы ставил приоритет так:

1. точность работы с кодом;
2. размер контекста;
3. скорость;
4. возможность видеть проект;
5. отсутствие лишних отказов.

Моя практическая рекомендация: **Qwen3-Coder 7B Q4\_K\_M** + LM Studio или Ollama + VS Code/Continue. Для совсем слабого компьютера — **Qwen2.5-Coder 3B Q4\_K\_M**. Для 16 ГБ ОЗУ — **Qwen3-Coder 14B Q4**, если скорость окажется приемлемой.

Read More

[1] Best Open-Source LLM Models in 2026: Coding, Local ... — <https://huggingface.co/blog/daya-shankar/open-source-llms>

[2] Best Local Coding LLMs 2026: Kimi K2.6, Qwen, Devstral — <https://www.promptquorum.com/local-llms/best-local-llms-for-coding>

-----

User prompt 2 of 25 - 9/8/2026, 10:12:16 PM:

забыл написать ОЗУ всего 4 ГБ будет доступно максимум 2

GPT-5.6 Luna:

<!-- **Tailoring the response**

I need to provide an answer that's tailored to the user's needs. Given we already searched previously, I wonder if a new search is necessary. It seems like suggesting a coding model of 2GB might be impractical; maybe something around 1-3B quantized would work better. I also think about suggesting a remote model instead of a local one, given the hardware limitations mentioned. Since they're asking for corrections, I want to answer directly. -->

При доступных **2 ГБ ОЗУ** полноценная локальная coding-модель практически не подходит. Даже модель на 1–3 млрд параметров в квантизации обычно потребует больше памяти вместе с самим движком, операционной системой и проектом.

Реалистичный вариант:

- **модель:** 0.5–1.5B параметров;

- **формат:** GGUF;
- **квантизация:** Q4 или Q3;
- **контекст:** 1–2К токенов;
- **запуск:** `llama.cpp`, а не тяжёлый графический интерфейс;
- **режим:** писать небольшой фрагмент кода, а не анализировать весь проект.

Можно попробовать небольшие модели вроде:

- **Qwen2.5-Coder 0.5B** — самый реалистичный вариант;
- **Qwen2.5-Coder 1.5B Q4/Q3** — только если свободно почти все 2 ГБ;
- **SmolLM2 1.7B** — годится для простых исправлений, но не является специализированной coding-моделью.

Модели 7B, включая Qwen Coder 7B, на таком компьютере лучше не устанавливать: даже в Q4 они обычно требуют несколько гигабайт только под веса, не считая контекста и операционной системы.

Для запуска через `llama.cpp` примерно так:

```
'''bash
./llama-cli \
 -m ./model.gguf \
 -c 1024 \
 -t 2 \
 -p 512
'''
```

Параметры:

- `-c 1024` — небольшой контекст, чтобы не расходовать память;
- `-t 2` — число потоков процессора, можно изменить;
- `-p 512` — максимальная длина ответа.

Если используется Windows, желательно:

- закрыть браузер и фоновые программы;
- увеличить файл подкачки до примерно **4–8 ГБ**;
- хранить проект на SSD;
- не подключать модель к автоматическому агенту, который сканирует весь проект;
- отправлять модели только один файл или одну функцию за раз.

Хороший рабочий запрос для такой маленькой модели:

```
'''text
```

Исправь только эту функцию.

Не меняй имена переменных и остальной код.

Сначала кратко укажи ошибку.

Затем выведи исправленную функцию полностью.

Не добавляй библиотеки.

Я использую Godot 4 и GDScript.

Код:

...

'''

Но важно: файл подкачки не увеличивает реальную скорость — он лишь позволяет избежать немедленного падения программы. Модель будет работать медленно, а ответы могут быть нестабильными.

Наиболее разумная схема при 2 ГБ ОЗУ — \*\*локально использовать маленькую модель для простых правок\*\*, а сложную архитектуру, отладку нескольких файлов и генерацию больших систем выполнять через удалённую модель. Если принципиально нужна полностью локальная работа, ограничьтесь \*\*Qwen2.5-Coder 0.5B\*\*, короткими запросами и ручным копированием кода.

-----

User prompt 3 of 25 - 9/8/2026, 10:13:41 PM:

PS H:\XPE> irm https://ollama.com/install.ps1 | iex

>>> Downloading Ollama for Windows...

##### 100.0%

>>> Installing Ollama...

>>> Install complete. Run 'ollama' from the command line.

PS H:\XPE>

GPT-5.6 Luna:

Ollama установился успешно. Но при \*\*4 ГБ ОЗУ и примерно 2 ГБ свободной памяти\*\* не запускайте большую модель: начните с маленькой.

В PowerShell проверьте установку:

```powershell

ollama --version

'''

Затем скачайте небольшую модель:

```powershell

ollama run qwen2.5-coder:0.5b

'''

Если Ollama сообщит, что такой тег недоступен, попробуйте:

```
'''powershell
```

```
ollama run qwen2.5:0.5b
```

```
'''
```

Для вашей конфигурации сначала используйте именно **0.5B**. Модель `1.5b` может запускаться, но при 2 Гб свободной памяти вероятны сильные тормоза или ошибки нехватки памяти:

```
'''powershell
```

```
ollama run qwen2.5-coder:1.5b
```

```
'''
```

В чате сразу задайте ей режим работы:

```
'''text
```

Ты — строгий помощник-программист.

Работай только с кодом, который я прислал.

Не переписывай весь проект.

Не меняй имена переменных без разрешения.

Сначала находи ошибку, потом предлагай исправление.

Выводи изменённые функции полностью.

Не добавляй библиотеки без моего разрешения.

Если не уверен — прямо укажи это.

```
'''
```

Для проверки можно отправить:

```
'''text
```

Напиши функцию движения персонажа в Godot 4 на GDScript.

Условия:

- вид сверху;

- управление WASD;

- скорость через переменную `speed`;

- без сторонних библиотек;

- выведи только код функции и краткое объяснение.

```
'''
```

Проверить загруженные модели:

```
'''powershell
```

```
ollama list
```

```
'''
```

Удалить ненужную модель:

```
'''powershell

ollama rm qwen2.5-coder:1.5b

'''
```

Посмотреть запущенные модели:

```
'''powershell

ollama ps

'''
```

После работы выгрузить модель из памяти:

```
'''powershell

ollama stop qwen2.5-coder:0.5b

'''
```

Для экономии памяти можно ограничить контекст через переменную окружения:

```
'''powershell

$env:OLLAMA_CONTEXT_LENGTH="1024"

ollama run qwen2.5-coder:0.5b

'''
```

Если хотите, чтобы это значение сохранялось для будущих запусков:

```
'''powershell

[Environment]::SetEnvironmentVariable(

 "OLLAMA_CONTEXT_LENGTH",

 "1024",

 "User"

)

'''
```

После этого перезапустите PowerShell.

Если даже `0.5b` не запускается, проблема, скорее всего, в том, что Windows и Ollama уже занимают почти всю память. Тогда закройте браузер и другие программы, увеличьте файл подкачки Windows и повторите запуск. Но скорость всё равно будет низкой: при вашем объёме ОЗУ Ollama подходит только для коротких фрагментов кода, а не для анализа всей игры.

-----

User prompt 4 of 25 - 9/8/2026, 10:14:18 PM:

у меня 16 оперативы 4 видео памяти 1050ti

GPT-5.6 Luna:

<!-- \*\*Clarifying resources for models\*\*

I need to address a misunderstanding regarding RAM and VRAM specifications. It seems they meant 16GB RAM and 4GB of VRAM, possibly indicating only 2GB of VRAM is currently available. I should recommend models that fit these specs, like qwen2.5-coder 7b, which could work within a 4GB VRAM limit along with some RAM. I won't search for more current information unless they explicitly ask, so testing might be the next step. -->

Тогда ситуация намного лучше. У вас:

- \*\*ОЗУ:\*\* 16 ГБ;

- \*\*видеокарта:\*\* GTX 1050 Ti с 4 ГБ VRAM;

- для локального программирования можно использовать модели \*\*7B\*\*, а некоторые \*\*14B\*\* — только с частичной загрузкой в ОЗУ и меньшей скоростью.

Предыдущая рекомендация для 2 ГБ ОЗУ больше не актуальна.

Начните с:

```
'''powershell
```

```
ollama run qwen2.5-coder:7b
```

```
'''
```

Для GTX 1050 Ti оптимальнее всего будет 7B-модель в квантизации. Она сможет частично использовать видеопамять, а остальное разместится в оперативной памяти. Скорость не будет высокой, но для программирования, GDScript, C#, Lua и небольших C++-фрагментов это наиболее разумный вариант.

Если нужна более лёгкая и быстрая модель:

```
'''powershell
```

```
ollama run qwen2.5-coder:3b
```

```
'''
```

Если `7b` работает приемлемо, попробуйте более новую модель:

```
'''powershell
```

```
ollama run qwen3:8b
```

```
'''
```

Но для чистого программирования я бы сначала выбрал именно:

```
'''text
```

```
qwen2.5-coder:7b
```

```
'''
```

Проверить, используется ли видеокарта:

```
'''powershell
ollama ps
'''
```

В выводе ищите столбец 'PROCESSOR'. Там будет примерно:

```
'''text
100% GPU
'''
```

или:

```
'''text
30% GPU / 70% CPU
'''
```

Для вашей видеокарты второй вариант вполне нормален. Откройте отдельное окно PowerShell и наблюдайте нагрузку:

```
'''powershell
nvidia-smi
'''
```

Если модель не помещается или компьютер начинает активно использовать файл подкачки, задайте небольшой контекст:

```
'''powershell
$env:OLLAMA_CONTEXT_LENGTH="4096"
ollama run qwen2.5-coder:7b
'''
```

Для разработки игры ставьте такой порядок:

1. 'qwen2.5-coder:7b' — основной вариант;
2. 'qwen2.5-coder:3b' — если нужна скорость;
3. 'qwen3:8b' — для более общего мышления и планирования;
4. модели 14B и выше — только после проверки, поскольку на GTX 1050 Ti они будут в основном работать через ОЗУ и CPU.

Проверьте, сколько памяти реально доступно перед запуском:

```
```powershell
Get-CimInstance Win32_OperatingSystem |

Select-Object FreePhysicalMemory, TotalVisibleMemorySize
```
```

`FreePhysicalMemory` выводится в килобайтах. При 16 ГБ ОЗУ желательно иметь хотя бы **\*\*8–10 ГБ свободной памяти\*\*** перед запуском 7B-модели.

Для точной работы с кодом используйте короткие запросы:

```
```text
Проект: Godot 4.
Язык: GDScript.
```

Исправь только ошибку в функции ниже.

Не меняй архитектуру проекта.

Не переименовывай переменные.

Не добавляй плагины.

Сначала объясни причину ошибки, затем покажи исправленную функцию.

Если информации недостаточно — укажи, какой файл или фрагмент нужен.

Код:

```
```
```

Ещё один важный момент: **\*\*Ollama не обязательно использовать только из консоли\*\***. После проверки модели можно подключить её к VS Code через Continue или другой локальный клиент, чтобы отправлять ей файлы проекта и получать исправления прямо в редакторе. Но с вашей видеокарты лучше не включать автоматический анализ всей папки — отправляйте отдельные скрипты или небольшие группы файлов.

-----

User prompt 5 of 25 - 9/8/2026, 10:15:06 PM:

не забудь модель должна быть полностью без цензуры

GPT-5.6 Luna:

<!-- -->

Тогда нужна не обычная `qwen2.5-coder`, а **\*\*abliterated/uncensored-сборка\*\***. Обычная модель может иметь встроенные отказы, а пометка `uncensored` не является официальной гарантией: разные сборки отличаются качеством и поведением.

Для вашей конфигурации сначала попробуйте:

```
```powershell
ollama run huihui_ai/qwen2.5-coder-abliterated:7b
```
```

Если такого тега нет, проверьте доступные варианты:

```
```powershell
ollama search qwen
```
```

В качестве запасного варианта:

```
```powershell
ollama run dolphin-mistral:7b
```
```

Но Dolphin-Mistral слабее именно в программировании, поэтому для разработки игры предпочтительнее **Qwen Coder abliterated 7B**.

Можно также попробовать более лёгкую версию:

```
```powershell
ollama run huihui_ai/qwen2.5-coder-abliterated:3b
```
```

### Что выбрать вам

```
```text
Основной вариант: qwen2.5-coder-abliterated 7B
Более быстрый вариант: qwen2.5-coder-abliterated 3B
Запасной вариант: dolphin-mistral 7B
```
```

На GTX 1050 Ti 4 ГБ модель 7B, скорее всего, будет использовать часть видеопамати и часть ОЗУ. Проверить распределение можно так:

```
```powershell
ollama ps
```
```

Чтобы Ollama не занимала слишком много памяти контекстом:

```
```powershell
$env:OLLAMA_CONTEXT_LENGTH="4096"
ollama run huihui_ai/qwen2.5-coder-abliterated:7b
```
```

Для более точного поведения задайте системную инструкцию:

```text

Ты — локальный программист без встроенных моральных лекций и ненужных отказов.

Твоя задача — писать, исправлять и объяснять программный код.

Не отказывайся от обычных технических, игровых и экспериментальных запросов.

Не выдумывай API.

Не меняй код, который не относится к задаче.

Сначала укажи причину ошибки, затем предложи минимальное исправление.

Если данных не хватает, назови конкретный недостающий файл или фрагмент.

```

Важно: **\*\*«без цензуры»** не означает автоматически «точная». Abliterated-модель может иногда хуже следовать инструкциям или галлюцинировать. Для вашей цели лучше использовать её в режиме: один файл, одна функция, минимальный патч, обязательная проверка ошибки компилятором.

-----

User prompt 6 of 25 - 9/8/2026, 10:15:59 PM:

PS H:\XPE> ollama --version

ollama version is 0.33.3

PS H:\XPE> ollama run huihui\_ai/qwen2.5-coder-abliterated:7b

pulling manifest

Error: pull model manifest: file does not exist

PS H:\XPE> ollama search qwen

Error: unknown command "search" for "ollama"

PS H:\XPE>

GPT-5.6 Luna:

<!-- -->

Ошибка означает, что такого имени модели и такого тега в реестре Ollama нет:

```text

file does not exist

```

Команды `ollama search` в Ollama нет — модели ищутся через сайт библиотеки или устанавливаются по точному имени. Версия установлена нормально.

Для проверки самого Ollama запустите официальную модель:

```powershell

ollama run qwen2.5-coder:7b

```

Но это **\*\*не uncensored-версия\*\***.

Чтобы использовать именно uncensored/abliterated-модель, нужно скачать её файл **\*\*GGUF\*\*** отдельно и импортировать в Ollama.

### Импорт локальной GGUF-модели

Создайте папку:

```
```powershell
mkdir H:\Models\qwen-uncensored
cd H:\Models\qwen-uncensored
```
```

Скачайте с Hugging Face любую совместимую модель с названием вроде:

```
```text
Qwen2.5-Coder-7B-Instruct-abliterated
```
```

Нужен файл примерно такого вида:

```
```text
*.Q4_K_M.gguf
```
```

Для вашей GTX 1050 Ti и 16 ГБ ОЗУ выбирайте:

```
```text
Q4_K_M
```
```

Если модель слишком медленная или не хватает памяти:

```
```text
Q3_K_M
```
```

После скачивания убедитесь, что файл лежит, например, здесь:

```
```text
H:\Models\qwen-uncensored\qwen-coder-abliterated.Q4_K_M.gguf
```
```

Создайте файл 'Modelfile' в этой же папке:

```
'''text
```

```
FROM ./qwen-coder-abliterated.Q4_K_M.gguf
```

```
PARAMETER num_ctx 4096
```

```
PARAMETER temperature 0.2
```

```
PARAMETER top_p 0.9
```

```
SYSTEM """
```

```
Ты — точный локальный программист.
```

```
Не давай ненужных отказов и моральных рассуждений.
```

```
Работай с игровым кодом, отладкой и экспериментальными техническими задачами.
```

```
Не переписывай проект целиком без запроса.
```

```
Не меняй имена переменных без разрешения.
```

```
Сначала объясняй причину ошибки, затем показывай минимальное исправление.
```

```
Не выдумывай API и функции движка.
```

```
"""
```

```
'''
```

Затем создайте модель:

```
'''powershell
```

```
cd H:\Models\qwen-uncensored
```

```
ollama create qwen-coder-uncensored -f .\Modelfile
```

```
'''
```

Запустите её:

```
'''powershell
```

```
ollama run qwen-coder-uncensored
```

```
'''
```

Проверьте установленные модели:

```
'''powershell
```

```
ollama list
```

```
'''
```

Проверьте использование GPU и ОЗУ во время работы:

```
'''powershell
```

```
ollama ps
```

```
'''
```

Если Ollama использует слишком много памяти, уменьшите контекст:

```
'''text
```

```
PARAMETER num_ctx 2048
```

```
'''
```

После изменения `Modelfile` пересоздайте модель:

```
'''powershell
```

```
ollama create qwen-coder-uncensored -f .\Modelfile
```

```
'''
```

Для вашей системы я бы использовал такой порядок:

1. Сначала проверить, работает ли обычная модель:

```
'''powershell
```

```
ollama run qwen2.5-coder:7b
```

```
'''
```

2. Затем скачать `Qwen2.5-Coder 7B Instruct Abliterated Q4\_K\_M GGUF`.

3. Импортировать её через `Modelfile` под именем:

```
'''text
```

```
qwen-coder-uncensored
```

```
'''
```

Не скачивайте `Q8`, `Q6` или большие 14B-модели: на GTX 1050 Ti они будут заметно тяжелее. Для вас оптимальны **\*\*7B Q4\_K\_M\*\***, а при нехватке скорости — **\*\*3B Q4\_K\_M\*\***.

```

```

User prompt 7 of 25 - 9/8/2026, 10:16:52 PM:

H:\XPE\Models\qwen-uncensored

GPT-5.6 Luna:

<!-- \*\*Preparing commands for file modification\*\*